

PHÂN LOẠI TRÊN HYPERSPHERE VỚI GÁN NHÃN-PROTOTYPE ĐỘNG (DL2PA)

Ngô Đình Luân - 240101017

Tóm tắt

- Lớp: CS2205.FEB2025
- Link Github của nhóm:
https://github.com/DinhLuan14/DL2PA_CVPR
- Link YouTube video:
- Tên thành viên: Ngô Đình Luân - MSSV : 240101017



Giới thiệu

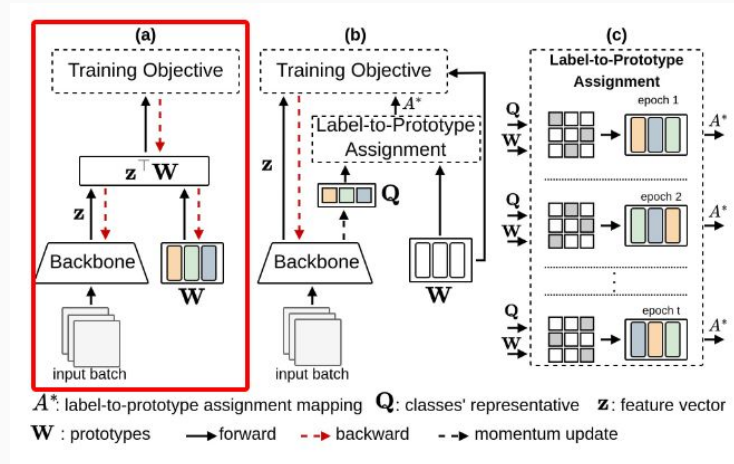
- Vấn đề với Parametric Softmax Classifier (PSC) truyền thống:
 - Static Assignment: Mỗi prototype được gán cố định cho một class trong suốt quá trình training
 - Thiếu linh hoạt: Không thể thích ứng với sự thay đổi của feature space trong quá trình học
 - Tối ưu không đầy đủ: Chỉ tối ưu backbone network, bỏ qua khả năng tối ưu assignment
- Xu hướng Non-parametric Classifiers:
 - Đề xuất thay thế PSC bằng non-parametric
 - Mục tiêu: tận dụng embedding space thông qua việc cố định vị trí các prototype

Mục tiêu

- Ý tưởng cốt lõi:
 - Dynamic Label-to-Prototype Assignment: Cho phép thay đổi việc gán nhãn cho prototype trong quá trình training
 - Orthogonal approach: Khác biệt hoàn toàn với các nghiên cứu trước đây
- Điểm mới:
 - Lần đầu tiên formalize bài toán assignment động như một optimization problem
 - Kết hợp gradient descent và bipartite matching trong một framework thống nhất
 -

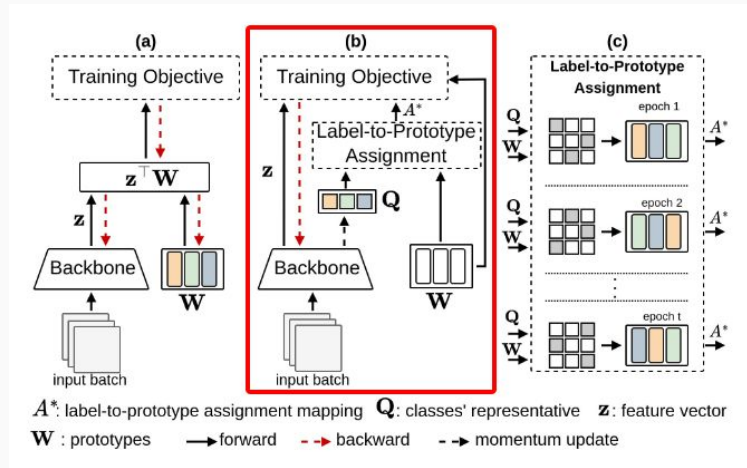
Nội dung và Phương pháp

- Figure 1: So sánh giữa phương pháp đề xuất và phương pháp trước đây:
- (a) Phương pháp truyền thống (PSC hoặc Fixed classifier):
Input data \rightarrow Backbone \rightarrow extract $\rightarrow (z) \rightarrow z^T W \rightarrow$ Loss



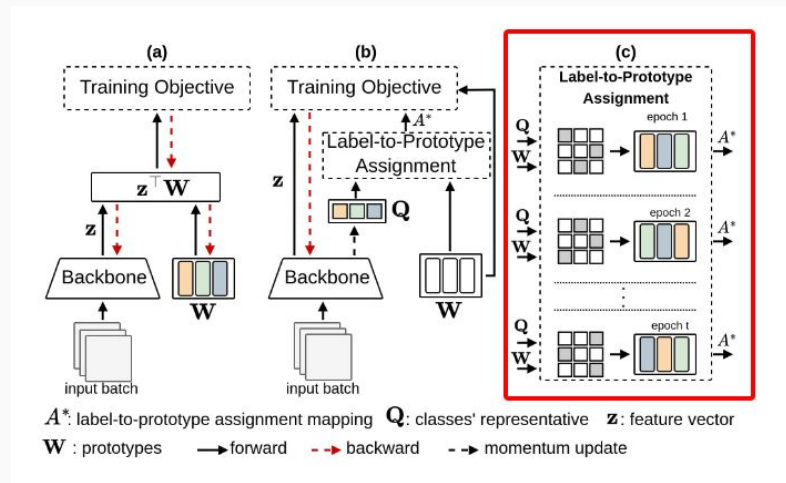
Nội dung và Phương pháp

- Figure 1: So sánh giữa phương pháp đề xuất và phương pháp trước đây:
- (b) Phương pháp đề xuất (DL2PA): Các prototype (W) được tạo trước và cố định vị trí trên hypersphere



Nội dung và Phương pháp

- Figure 1: So sánh giữa phương pháp đề xuất và phương pháp trước đây:
- (c) Ví dụ minh họa thay đổi gán lớp (mỗi epoch mỗi màu - lớp khác nhau) cho prototype qua từng epoch



Nội dung và Phương pháp

Dynamic Assignment Algorithm:

1. Forward Pass và Feature Extraction
2. Compute Assignment Matrix:
 - a. Tính similarity matrix giữa features và tất cả prototypes
 - b. Sử dụng Hungarian algorithm để tìm optimal assignment
3. Loss Computation:
 - a. Balanced: BLoss
 - b. Long-tail: LTloss
4. Momentum Update: Cập nhật exponential moving average của prototypes giúp ổn định quá trình training

Kết quả dự kiến

- Chính xác Top-1 vượt PSC $\geq 1\%$ trên CIFAR-100 và ImageNet-200.
- Trên CIFAR-100-LT, đạt $\geq 50\%$ Top-1 ($d=128$) – cao hơn mọi baseline cùng chiều.
- Với $d=\frac{1}{2}c$, độ chính xác ngang ETF dùng $d \approx c$; chứng minh khả năng giảm 50 % chiều mà vẫn giữ hiệu suất.
- Giảm Expected Calibration Error (ECE) so với PSC nhờ prototype cố định và loss “pull-only”.

Tài liệu tham khảo

- [1]. Mohammad Saeed Ebrahimi Saadabadi, Ali Dabouei, Sahar Rahimi Malakshan, Nasser M. Nasrabadi. Hyperspherical Classification with Dynamic Label-to-Prototype Assignment. Proc. CVPR 2024.
- [2]. Yibo Yang et al. Inducing Neural Collapse in Imbalanced Learning: Do We Really Need a Learnable Classifier? NeurIPS 2022.
- [3]. Pascal Mettes, Elise van der Pol, Cees Snoek. Hyperspherical Prototype Networks. NeurIPS 2019.
- [4]. Weiyang Liu et al. Learning towards Minimum Hyperspherical Energy. NeurIPS 2018.